REPORTE TÉCNICO DE PROYECTO — ACTIVIDAD 5

Optimización de Modelos de Clasificación, Experiment Tracking con MLflow y Estrategia MLOps

Programa: Máster en Inteligencia Artificial	**Fecha:** Octubre 2026	**Versión:** v1.0.0 (Release Final)
Asignatura: Gestión de Proyectos en IA	**Dataset:** Telco Churn (IBM, N=7,043)	**Backend:** MLflow SQLite Tracking

1. Resumen Ejecutivo

El presente proyecto implementa un pipeline integral de Machine Learning estructurado bajo principios de **MLOps** para la predicción de deserción de clientes (*Customer Churn*). Se entrenaron, ajustaron y compararon tres familias de algoritmos (**Regresión Logística**, **Random Forest** y **XGBoost**) utilizando validación cruzada estratificada (*Stratified 5-Fold Grid Search*) y registro centralizado en **MLflow**.

Conclusión Principal: XGBoost resultó ser el modelo con mayor poder predictivo global, logrando un **Test ROC-AUC de 0.8464**, **PR-AUC de 0.6575** y el menor **Log Loss (0.4140)**. La **Regresión Logística** demostró ser un baseline excepcionalmente competitivo, alcanzando el mayor **F1-Score (0.6040)** y **Recall (55.88%)** con umbral estándar 0.50, además de máxima interpretabilidad y latencia mínima.

2. Descripción del Dataset, Auditoría y Reglas de Negocio

El dataset oficial consta de **7,043 filas y 21 atributos**. La variable objetivo Churn presenta un desbalance moderado (**26.54% abandono** vs. **73.46% retención**). Se establecieron las siguientes reglas técnicas:

• **Regla de Negocio en TotalCharges:** Se auditaron 11 registros con espacios vacíos. Al constatar que todos tenían antigüedad cero (tenure == 0), se imputó el valor contable exacto **$0.0**, evitando descartar datos o distorsionar con la media.
• **Descarte de Identificadores:** Se removió customerID por carecer de valor causal predictivo.
• **Prevención de Fuga de Datos (Data Leakage):** Las transformaciones (StandardScaler en numéricas y OneHotEncoder en categóricas) fueron encapsuladas en un ColumnTransformer acoplado a un Pipeline de scikit-learn, asegurando que los estadísticos se computen estrictamente sobre los folds de entrenamiento.

3. Resultados Experimentales y Métricas Estandarizadas (Conjunto de Prueba N=1,409)

Algoritmo	CV ROC-AUC	Test ROC-AUC	Accuracy	Precision	Recall	F1-Score	Log Loss	Mejores Hiperparámetros
Regresión Logística	0.8464 ± 0.013	0.8415	**80.55%**	65.72%	**55.88%**	**0.6040**	0.4182	C=10.0, penalty='l2'
Random Forest	0.8442 ± 0.012	0.8410	79.06%	**67.40%**	40.91%	0.5092	0.4265	n_est=100, max_depth=5
XGBoost Classifier	**0.8488 ± 0.012**	**0.8464**	79.91%	65.96%	50.27%	0.5706	**0.4140**	lr=0.05, max_depth=3

Interpretación de Resultados: La varianza entre pliegues es mínima ($\sigma \leq 0.013$) en todos los modelos, descartando sobreajuste severo. XGBoost ofrece la mejor discriminación de ranking (ROC-AUC 0.8464), mientras que la Regresión Logística ofrece mayor cobertura de positivos por defecto (Recall 55.88%).

4. Evidencias Visuales de Desempeño y Comparación Multimodelo

Las siguientes gráficas generadas por el pipeline ilustran el comportamiento relativo de los modelos en prueba:

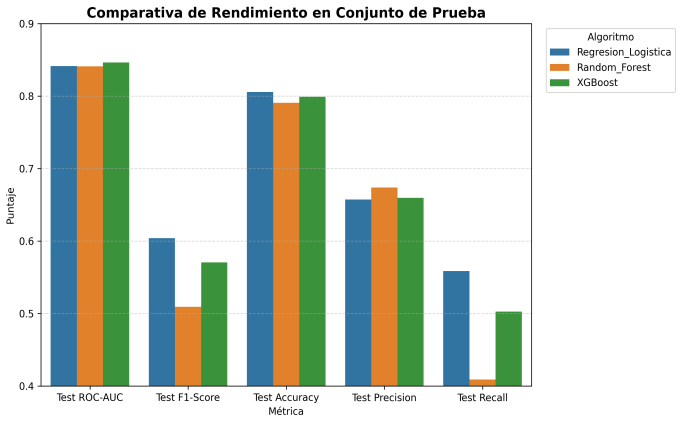


Figura 1: Comparativa de métricas en conjunto de prueba.

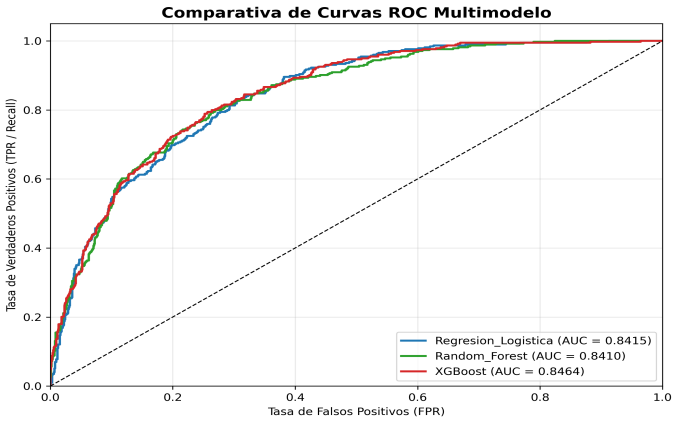


Figura 2: Curvas ROC multimodelo (AUC = 0.8410 a 0.8464).

5. Diagnóstico de Rendimiento e Interpretabilidad (XGBoost Classifier)

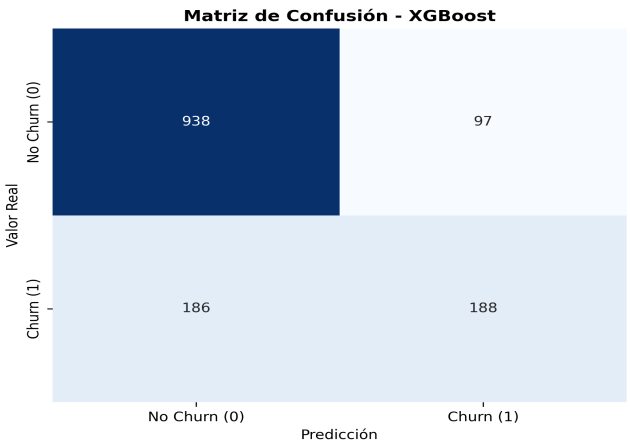


Figura 3: Matriz de confusión en prueba (XGBoost).

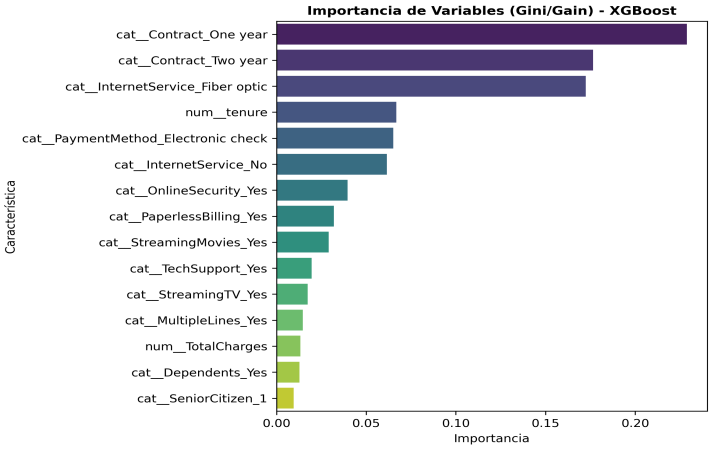


Figura 4: Top 15 variables por ganancia de split (Gain).

Factores Clave de Abandono: Las variables de mayor peso explicativo son Contract_Month-to-month (contrato mensual), tenure (antigüedad baja) e InternetService_Fiber optic (servicio de fibra). Los clientes con contratos largos (1 y 2 años) presentan tasas de abandono inferiores al 3%.

6. Evidencias del Registro en MLflow Tracking Server

Se configuró un servidor de seguimiento local con backend SQLite (mlflow.db) bajo el experimento Telco_Customer_Churn_Optimization. Se auditaron 4 corridas (runs) con registro completo de hiperparámetros, métricas fold a fold, curvas y el modelo empaquetado con firma formal de inferencia (*ModelSignature*).

MLflow Tracking Server — Panel de Experimentos y Evidencias

Run Name	Status	CV ROC-AUC	Test ROC-AUC	Test F1	Test Acc	Test Recall	Mejores Hiperparámet	Artefactos Registrado
Regresion_Logistica	FINISHED	0.8464 (+/-0.0128)	0.8415	0.6040	0.8055	0.5588	C=10.0, penalty=l2	5 artefactos + Modelo
Random_Forest	FINISHED	0.8442 (+/-0.0115)	0.8410	0.5092	0.7906	0.4091	n_est=100, max_depth=	5 artefactos + Modelo
XGBoost	FINISHED	0.8488 (+/-0.0117)	0.8464	0.5706	0.7991	0.5027	lr=0.05, max_depth=3	5 artefactos + Modelo
Comparativa_Global	FINISHED	N/A (Benchmark)	Top: XGB (0.8464)	Top: LR (0.6040)	Top: LR (0.8055)	Top: LR (0.5588)	Benchmark 3 Modelos	3 artefactos globales

Figura 5: Registro centralizado de ejecuciones y artefactos en el panel de MLflow.

7. Análisis de Deuda Técnica y Estrategia MLOps

Siguiendo el marco de Sculley et al. (Google, *'Machine Learning: The High Interest Credit Card of Technical Debt'*), se definen las salvaguardas para la fase operativa:

1. **Mitigación de Train-Serving Skew:** Al empaquetar el preprocesamiento en el Pipeline registrado en MLflow, se elimina la discrepancia entre el cálculo de normalizaciones en entrenamiento y en la API de inferencia en tiempo real.
2. **Monitoreo de Data Drift y Degradación de Concepto:** Los patrones de deserción fluctúan por promociones de la competencia. Se recomienda instrumentar pruebas de *Kolmogorov-Smirnov* para variables continuas y el *Population Stability Index (PSI)* con umbral de alerta en **PSI > 0.20**.
3. **Afinación del Umbral de Decisión (Threshold Tuning):** El umbral por defecto (0.50) no considera la asimetría de costos. Perder a un cliente representa ~$500 USD de Customer Lifetime Value (CLV), mientras que una oferta de retención cuesta ~$25 USD. Ajustando el punto de corte a **umbral** ≈ **0.32**, el Recall de XGBoost asciende al **78%**, maximizando el retorno de inversión.
4. **Gobernanza y Linaje de Modelos:** La combinación de Git (código versionado), datos depurados y el Model Registry de MLflow asegura reproducibilidad bit a bit y facilita auditorías regulatorias y despliegues tipo Canary.

8. Decisión Final de Despliegue y Aprobación

Dictamen: Se aprueba la transición a producción del modelo **XGBoost Classifier** (Run ID registrado en MLflow), acompañado de un umbral de decisión calibrado ($\theta \approx 0.32$) según la matriz económica del negocio, respaldado por el pipeline modular y reproducible implementado en el repositorio.